

STACK112

판례 탐색을 학습 루프로 바꾼 온디바이스 AI 앱

경찰 시험 준비생이 판례를 찾고, 이해하고, 문제로 확인하고, 오답을 다시 학습하는 전 과정을 iPhone 안에서 완성했습니다.

0 1.0.0

완전 온디바이스

iPhone / iPad

임재현 · Product / iOS · AI · Release

기획 · 설계 · 개발 · 배포

[APP STORE에서 보기](#)

[GITHUB 저장소](#)

Portfolio Case Study · Repository snapshot: 2026-06-19 · Document: 2026-08-10



검색을 멈추고, 학습을 이어가게

판례 확인을 위해 검색 사이트와 자료집을 오가는 시간을 하나의 학습 흐름으로 압축했습니다.

THE PROBLEM

판례는 찾는 순간보다 확신하는 순간이 어렵다

01 탐색 비용

문제 풀이 중 사건명·쟁점·원문을 여러 채널에서 다시 검색하며 학습 흐름이 끊깁니다.

02 신뢰 비용


일반 LLM의 근거 없는 답변과 부정확한 인용은 법률 학습에서 치명적입니다.

03 복습 단절


판례를 이해해도 문제 적용과 오답 복습으로 연결되지 않으면 기억에 남지 않습니다.

PRIMARY USER 경찰 공무원 시험 준비생

확장 사용자: 경찰학과·행정학과 등 판례 기반 학습자



ONE CONTINUOUS LOOP



근거 docs/project/Project_Description.md · docs/project/PRD_AI_SYS.md · docs/project/User_Journey_Scenario_AI_SYS.md

한 번의 입력이 복습 자산이 되기까지

홈 대시보드, 판례 스캔, AI 요약, OX 퀴즈와 오답노트를 하나의 탭 구조로 연결했습니다.




01 · INPUT

카메라·사진·텍스트에서 판례 지문을 가져오고 Apple Vision으로 한국어 OCR을 수행합니다.



02 · UNDERSTAND

판례 요약, 핵심 쟁점, 판결 결론, 시험 포인트와 추출 키워드를 학습 카드로 제공합니다.



03 · APPLY

판례 문맥에서 OX 문제를 생성하고 선택 즉시 정답과 근거를 확인합니다.

DESIGN PRINCIPLE

검색 결과보다 다음 행동

요약 화면에서 퀴즈와 메모로 바로 이동해 학습 흐름을 유지합니다.

PERSONALIZATION

오답이 다음 학습을 결정

취약 키워드와 자주 틀린 영역을 다시 홈과 오답노트에 노출합니다.

TRUST

불확실성을 숨기지 않기


원문 부족·결론 미검출 시 자동 생성 대신 확인 필요 상태를 표시합니다.

근거 code/ios/AISYSApp/Sources/RootTabView.swift · NewMainScreens.swift · SearchFlowViews.swift · OCRView.swift

서버를 제거하고, 학습 엔진을 기기 안으로

초기 FastAPI·PostgreSQL 구조에서 완전 온디바이스로 전환해 네트워크 의존과 운영 비용을 제거했습니다.

ON-DEVICE DATA FLOW



CORE MODULES

LLMService	추론 상태·캐시·폴백 조율
LegalAnalyzer	5개 법률 도메인 분류와 함정 카탈로그
IssueDictionary	60+ 법률 쟁점 탐지·확장
CaseSearch	제목×3·키워드×2·본문×1 검색
Similarity	한국어 임베딩·토큰·법률 키워드 재정렬
StudyStore	학습·오답 이력 로컬 지속성

ARCHITECTURE DECISION

On-device First

외부 API 0

Data Not Collected

얻은 것

오프라인 사용, 개인정보 외부 전송 차단, EC2/RDS 비용 0, 인증·CORS 장애 제거

감수한 것

783MB 앱 크기, 저사양 기기 메모리·발열 제약, 1B 모델의 생성 품질 한계

보완

규칙 기반 폴백, 응답 캐시, 도메인 분석기, 제한된 생성 역할로 품질 경계를 명확히 했습니다.

807MB

32

60+

5

번들 모델

Llama 3.2 1B Q4

응답 캐시

summary / OX / RAG

법률 쟁점

도메인 사전

법률 도메인

함정 8~14패턴

근거 docs/adr/0001-ondevice-first.md · docs/project/Technology_Stack_AI_SYS.md · code/ios/README.md

작은 모델을 믿을 수 있게 만드는 설계

생성 모델 하나에 판단을 맡기지 않고 검색, 도메인 규칙, 유사도, 풀백을 조합했습니다.

HYBRID INTELLIGENCE

- 입력 정리**
OCR 띄어쓰기 보정과 법률 텍스트 정규화
- 후보 검색**
제목·키워드·본문 가중치와 사전 확장
- 유사도 재정렬**
 $0.65 \text{ 임베딩} + 0.25 \text{ Jaccard} + 0.10 \text{ 법률 신호}$
- 도메인 분석**
5개 도메인 분류, 60+ 쟁점, 함정 패턴 주입
- 제한적 생성**
LLM은 OX 변형·결론 라벨링·짧은 요약 강화에 집중
- 안전한 풀백**
모델 로드 실패 또는 출력 파싱 실패 시 규칙 기반 결과 제공



GROUNDING

내부 판례 문맥 우선

검색된 원문과 메타데이터를 기반으로 요약하고, 데이터가 부족하면 단정하지 않습니다.

PERSONALIZATION

취약 키워드 주입

오답 이력의 취약 키워드를 프롬프트와 복습 목록에 반영합니다.

DIVERSITY

함정 카탈로그 서플

같은 판례에서도 서로 다른 시험 함정을 반복 학습하도록 구성합니다.

근거 LegalAnalyzer.swift · LegalIssueDictionary.swift · LocalCaseSearchEngine.swift · LocalSimilarityEngine.swift · LLMService.swift

저사양 iPhone에서도 끝까지 흐름을 유지하다

iPhone 12 mini 실기기 기준으로 OCR·LLM·디코딩을 메인 스레드에서 분리하고 추론 크기를 줄였습니다.

BEFORE

88.2%

CPU

열 상태 Serious

213MB

메모리

LLM 컨텍스트 150MB

OCR 5~10초 메인 스레드 블로킹
llama_decode 40~50% CPU
최대 512 생성 토큰

AFTER

60%

CPU

문서 기준 32% 감소

120MB

메모리

문서 기준 44% 감소

OCR·JSON·LLM 백그라운드 처리
컨텍스트 2048 → 512
최대 생성 512 → 160 토큰

OPTIMIZATION MOVES

1

메인 스레드 해방

Vision OCR, JSON 디코딩, llama.cpp 추론을 백그라운드로 이동

2

추론 예산 제한

n_ctx·batch를 75%, 스레드를 67%, 생성 토큰을 69% 축소

3

입력 정규화

프롬프트 1,200자 상한으로 토큰화 비용 40% 감소

4

캐시와 부분 수락

동일 입력 재추론을 건너뛰고 유효 결과는 풀백으로 보충

95%+

정형 출력 파싱

문서의 테스트 기준

3~5초

160 토큰 생성

내부 측정 문서

0초

OCR UI 블로킹

Task.detached 전환

근거 docs/research/OPTIMIZATION_COMPLETE.md · code/ios/README.md | 수치는 저장소의 내부 측정 문서 기준

코드가 아니라 제품으로 끝내기

빌드·테스트·보안·문서·운영 체크를 PR과 main 릴리스 파이프라인에 연결하고 App Store 배포까지 완료했습니다.

10

GitHub Actions

workflow files

2

iOS XCTest

오답·기록 회귀

85

Markdown 문서

ADR·운영·API 포함

179

Repository commits

전체 Git 이력

DELIVERY PIPELINE



RELEASE EVIDENCE

v1.0.0 · 2026-05-28

실기기 검증

iPhone 12 mini(A14, 4GB)에서 OCR → 분류 → 요약 → OX → 검색 → 복습 전체 흐름 확인

배포

Release 설치, Archive, App Store Connect 업로드와 App Store 출시 완료

APP STORE ↗

OPERATIONS

관측 지표

model load success · first summary latency · fallback activation · crash-free sessions

경보 기준

fallback > 15% · first summary p95 > 3s · crash-free < 99.5%

운영 문서

On-device Runbook · Observability · Model Card · Changelog · Retrospective

SCOPE NOTE

FastAPI·PostgreSQL·pgvector는 서버형 대안과 IR 실험을 보존한 레거시 코드이며, Android는 Jetpack Compose 스캐폴드 단계입니다. 현재 출시 제품은 iOS 온디바이스 앱입니다.

근거 [.github/workflows](#) · [code/ios/AISYSAppTests](#) · [docs/operations](#) · [CHANGELOG.md](#) · [README.md](#)

기획, 구현, 출시를 하나의 책임으로

기획 문서에서 시작한 아이디어를 아키텍처 전환, iOS 통합, 운영 기준과 App Store 출시까지 연결했습니다.

MY ROLE

임재현

Product Owner · Solo Developer

제품과 기술 방향

수험생 문제 정의, 온디바이스 전환, LLM 역할 축소와 규칙 기반 보안의 우선순위 결정

iOS·AI 통합

SwiftUI 사용자 흐름, OCR·검색·요약·OX·오답 복습, LlamaSwift 추론과 로컬 저장 연결

품질과 출시

CI/CD, 온디바이스 헬스체크, 운영 문서, App Store 메타데이터·개인정보·배포 절차 정리

179


Git commits

동일 소유자 alias 합계

12,736

Swift LOC

Sources 기준



LEARNED 01

AI 품질은 모델 크기만의 문제가 아니다

검색 신호, 도메인 규칙, 출력 검증과 폴백을 설계 하면 작은 모델도 명확한 역할 안에서 제품 가치를 만들 수 있습니다.

LEARNED 02

아키텍처는 운영 조건까지 포함한다

백엔드 제거는 비용만 줄인 것이 아니라 개인정보, 장애 지점, 심사 대응과 오프라인 경험을 함께 단순화했습니다.

NEXT

평가를 제품 지표로 확장

다음 단계는 표본 사용자 평가, 검색 성공률, 첫 요약 지연과 오답 복습 재방문율을 실제 사용 데이터로 검증하는 것입니다.

End-to-end ownership

기획 · UX · iOS · 온디바이스 AI · CI/CD · App Store 배포

근거 docs/project/Project_Description.md · repository Git history · README.md · RETROSPECTIVE.md

SOURCE github.com/acertainromance401/STACK112